mucuri

December 3, 2019

1 PREVISÃO DA VELOCIDADE DO VENTO A CURTO PRAZO US-ANDO REDES NEURAIS ARTIFICIAIS EM MUCURI, BAHIA

1.1 Configuração

Realizando imports necessários.

```
import os
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd

from datetime import datetime
from IPython.display import SVG
from keras import backend as K
from keras.callbacks import ModelCheckpoint
from keras.layers import Dense
from keras.models import Sequential
from keras.optimizers import SGD, Adam, RMSprop
from keras.utils import model_to_dot
from sklearn.preprocessing import MinMaxScaler
```

Using TensorFlow backend.

Incluindo função que calcula o Coeficiente de correlação de Pearson r.

```
[2]: def r2_loss(y_true, y_pred):
    SS_res = K.sum(K.square(y_true - y_pred))
    SS_tot = K.sum(K.square(y_true - K.mean(y_true)))
    return 1 - SS_res / (SS_tot + K.epsilon())
```

Definição do modelo.

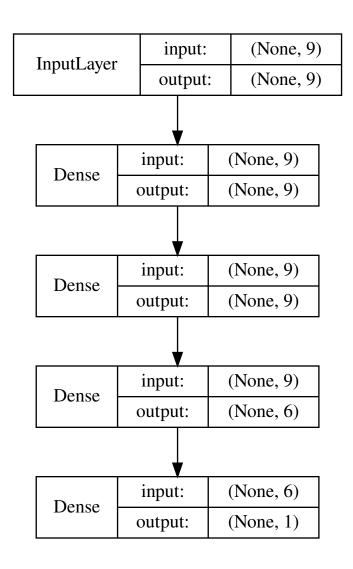
```
[60]: class MucuriModel:
    def __init__(self):
        self.model = None
        self._build_model()
```

```
def _build_model(self):
    if self.model is None:
        self.model = Sequential()
        self.model.add(Dense(9, input_shape=(9,)))
        self.model.add(Dense(9, activation="tanh"))
        self.model.add(Dense(6, activation="tanh"))
        self.model.add(Dense(1, activation="linear"))
        self.model.compile(
            loss="mean_squared_error",
            optimizer=Adam(lr=0.01),
            metrics=["mse", "mae", r2_loss],
def train(self, X, Y, X_test=None, Y_test=None):
    assert self.model is not None
    checkpoint = ModelCheckpoint(
        filepath="./weights.hdf5", save_best_only=True, monitor="mse"
    return self.model.fit(
        Χ,
        Υ,
        validation_data=(X_test, Y_test)
        if X_test is not None and Y_test is not None
        else None,
        verbose=0,
        epochs=65,
        callbacks=[checkpoint],
    )
def predict(self, data):
    assert self.model is not None
    return self.model.predict(data)
```

Foi utilizada a configuração 5 para a construção desse modelo, conforme especificado no paper. A quantidade de épocas foi definida como 65, a função de loss foi definida como a de mean squared error e as métricas MSE, MAE e r2 são usadas para a avaliação da performance. O otimizador Adam foi utilizado, configurado com o learning rate de 0.01.

```
[61]: model = MucuriModel()
SVG(model_to_dot(model.model, show_shapes=True, show_layer_names=False).

→create(prog='dot', format='svg'))
[61]:
```



1.2 Leitura e normalização dos dados

Lendo o arquivo que contém os dados a serem analisados.

```
[5]: _file = pd.ExcelFile("./Mucuri_novo_semNaN_torre150m.xlsx")
```

```
df = _file.parse("Dados anemo")
```

Carregando os dados de treino e teste, ordenando as colunas da seguinte maneira:

```
pressão, umid, temp, dir_1, v_anemo2, hora, ano, mês, dia
```

As informações referentes às datas (i.e. ano, mês e dia) foram colocadas por último, já que a sua repetição na massa de dados dificulta a convergência do modelo.

```
cols = X_train.columns.tolist()
cols = cols[::-1]
X_test = X_test[cols]
```

Realizando a normalização com minmax.

```
[8]: scaler = MinMaxScaler()

X_train = scaler.fit_transform(X_train.values)
X_test = scaler.fit_transform(X_test.values)
```

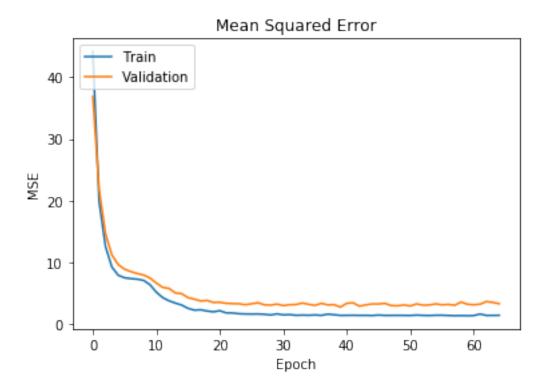
1.3 Treino

Realizando o processo de treino do modelo, incluindo dados de validação.

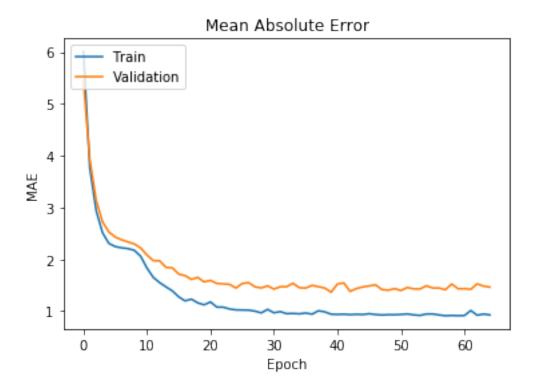
```
[62]: training_history = model.train(X_train, Y_train.values, X_test, Y_test.values)
```

1.4 Avaliação

```
[63]: plt.plot(training_history.history["mse"])
   plt.plot(training_history.history["val_mse"])
   plt.title("Mean Squared Error")
   plt.ylabel("MSE")
   plt.xlabel("Epoch")
   plt.legend(["Train", "Validation"], loc="upper left")
   plt.show();
```

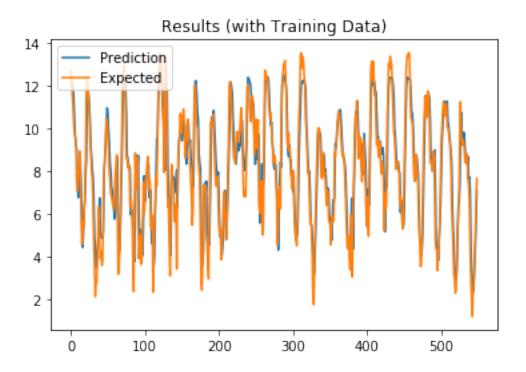


```
[64]: plt.plot(training_history.history["mae"])
   plt.plot(training_history.history["val_mae"])
   plt.title("Mean Absolute Error")
   plt.ylabel("MAE")
   plt.xlabel("Epoch")
   plt.legend(["Train", "Validation"], loc="upper left")
   plt.show();
```



```
[65]: predictions = [model.predict([[value]])[0][0] for value in X_train]

plt.plot(predictions)
plt.plot(Y_train.values)
plt.title("Results (with Training Data)")
plt.legend(["Prediction", "Expected"], loc="upper left")
plt.show();
```



```
[66]: predictions = [model.predict([[value]])[0][0] for value in X_test]

plt.plot(predictions)
plt.plot(Y_test.values)
plt.title("Results (with Test Data)")
plt.legend(["Prediction", "Expected"], loc="upper left")
plt.show();
```

